



结构变化的拓扑空间结构域识别

答辩人：张筱

指导老师：田德朝



| CONTENTS

1

研究背景

2

研究内容

3

研究结果

4

结果总结与研究计划






研究背景


研究背景

- 1、 **Hi-C 技术**捕捉到的染色质三维空间结构的相关信息可以形成**高维 Hi-C 矩阵**，揭示了染色体被分为**拓扑空间结构域**（topologically associated domains，**TADs**）。很多先前的研究已经表明了 TADs 在细胞类型之间是稳定的，但也有越来越多的研究在疾病细胞、细胞分化之间均发现了**差异 TADs**（**reorganized TADs**）。





K562

chr14:22,600,000-24,600,000




研究背景


3、有研究发现**结构变异（structural variations, SVs）**的出现会导致肿瘤抑制基因的缺失或原癌基因复制，促进致癌性融合基因的形成，并且有可能引起致癌基因表达的上调。



Orientation of fusion: 3' to 5', or +-



Orientation of fusion: 5' to 3', or --





Orientation of fusion: 5' to 5', or --



研究内容

研究缺陷

- 1、原先方法没有针对性考虑单细胞数据的高稀疏性；
- 2、研究在统计量的计算中使用了最大特征根，忽略了其他特征根所蕴含的信息；
- 3、实验的检出率依旧有 30% 左右的 差异 TADs 没有被检测出来；



研究内容

没有针对性考虑数据的高稀疏性

忽略了其他特征根



大维随机矩阵

线性谱统计量



对 bulkHi-C 数据探

测差异 TADs 提出更

准确适用的**方法**

主要研究内容：基于高维随机矩阵的**半圆率**和考虑阶跃函数的**高斯矩阵经验**


光谱分布（ESD）的收敛速度判断发生差异变化的拓扑空间结构域

研究方法

本研究主要通过**假设检验**方法探测 差异 TADs :

H_0 : 两种生物状态下的 Hi-C 接触矩阵不存在差异 (没有发生结构变化)

H_1 : 两种生物状态下的 Hi-C 接触矩阵存在差异 (发生了结构变化)





选题意义

- 1、解释不同生物条件下三维空间结构的差异与转录调控变化之间的关系；
- 2、更全面阐释三维基因组与疾病发生之间的**强关联关系**；
- 3、提高差异 TADs 的**识别检出率**；
- 4、为疾病复杂致病机制的理解与新型治疗方案的开发提供新视角；
- 5、验证了 SVs 与 差异 TADs 之间的高度相关性。

理论依据

1、高斯矩阵的半圆定律

令 W_n 为 n 维的高斯矩阵，标准化后的高斯矩阵 $(n^{-1/2}W_n)$ 的 n 个特征值的经验分布 F_n 被称为高斯矩阵的经验光谱分布 (empirical spectral distribution, ESD)，并且该分布以概率 1 收敛于半圆定律 F ，其密度由下式给出：

$$F' = \begin{cases} \frac{1}{2\pi} \sqrt{4 - x^2}, & \text{if } |x| \leq 2; \\ 0, & \text{otherwise} \end{cases}$$

当 $n \rightarrow \infty$ 时， $\mathbb{E}F_n$ 收敛于半圆定律并且有密度函数：

$$F(dx) = \frac{1}{2\pi} \sqrt{4 - x^2} dx, \quad x \in [-2, 2]$$



理论依据

1、考虑阶跃函数（step function）的高斯矩阵经验光谱分布（ESD）的收敛速度

$$G_n \triangleq n \int_{-\infty}^{\infty} f(x)[F_n - F](dx), \quad f \in C^4(\mathcal{U})$$

实数高斯矩阵的谱经验过程 $G_n = \{G_n(f): f \in C^4(\mathcal{U})\}$ 在有限维上弱收敛于高斯过程 $G := \{G(f): f \in C^4(\mathcal{U})\}$, 并且具有均值:

$$\mathbb{E}G(f) = \frac{\kappa - 1}{4} [f(2) + f(-2)] - \frac{\kappa - 1}{2} \tau_0(f) + (\sigma^2 - \kappa) \tau_2(f) + \beta \tau_4(f)$$


方差:

$$\begin{aligned} c(f, g) &\triangleq \mathbb{E}[\{G(f) - \mathbb{E}G(f)\}\{G(g) - \mathbb{E}G(g)\}] \\ &= \frac{1}{4\pi^2} \int_{-2}^2 \int_{-2}^2 f'(t)g'(s)V(t, s)dt ds \end{aligned}$$



研究结果

金标准数据下的检出率



函数 $f(x)$	检出率
$\ln(1+x^2)$	64.79
x	0
x^2	19.72
x^3	56.34
e^x	38.03

- (1) 观察金标准数据，发现不同函数下的检出率差距比较大
- (2) 三个函数交集为 11，并集为 95，检出率为 66.9014%
- (3) 四个函数交集为 11，并集为 105，检出率为 **73.9437%**，高于 **68.493%**



DiffDomain 的 R-package

开发

add files via upload	diffDomain / diffdomain-R /	Go to file
shinohara-xiao Add files via upload	bc8b73a on Mar 11	History
..		
R	Add files via upload	3 months ago
man	Add files via upload	3 months ago
DESCRIPTION	Add files via upload	3 months ago
LICENSE	Add files via upload	3 months ago
NAMESPACE	Add files via upload	3 months ago
diffdomain_0.1.0.tar.gz	Add files via upload	3 months ago

Examples

1. comapre single TAD

```
comp2domains_by_twtest(1,163500000,165000000,  
  "https://hicfiles.s3.amazonaws.com/hiseq/gm12878/in-situ/combined.hic",  
  "https://hicfiles.s3.amazonaws.com/hiseq/k562/in-situ/combined.hic",  
  reso = 10000,  
  ofile = "package-single-test")
```

2. multiple comparison

```
comp2domains_by_twtest_parallel(  
  "https://hicfiles.s3.amazonaws.com/hiseq/gm12878/in-situ/combined.hic",  
  "https://hicfiles.s3.amazonaws.com/hiseq/k562/in-situ/combined.hic",  
  "GSE63525_GM12878_primary+replicate_Arrowhead_domainlist.txt",  
  ofile = "package-multiple-test")
```

<https://github.com/Tian-Dechao/diffDomain/wiki/Usage-of-the-R-version-of-diffDomain>

SVs - Used Data


研究选择 **K562**（慢性髓系白血病细胞），**DIPGXIII** 和 **DIPG007**（神经胶质瘤细胞），对应使用的数据如下 (choose 25kb)：

N	Condition1	Condition2	SVs
1	GM12878	K562	45
2	NHA	DIPG007	38
3	NHA	DIPGXIII	27

对于 SVs 与 TADs 以及 差异 TADs 之间，我们将从 SV 以及 breakpoints 两个角度来分析：

- (1) SV overlap with TADs / reorganized TADs
- (2) SV have breakpoints lie in TADs / reorganized TADs

Reorganized TADs are enriched with SVs



结论:

(1) K562 中 42.86% 的 SVs 在差异 TADs 中, 显著高于随机试验结果;



(2) K562 中有 33 个 SVs 覆盖 GM12878 或 K562 TADs ; 其中 84.85% 的 SVs 与差异 TADs 有关;

(3) SVs 与差异 TADs 的高度相关性进一步证明了 差异 TADs 的生物学相关性。

SV 与 reorganized TADs

K562 中，33 个与 TADs 相关的 SV 中，有 28 个 SV 与 差异 TADs 有关联，探究 SV 类型与差异 TADs 之间的关系，发现：

(1) 出现与 TADs 相关而与 差异 TADs 无关的情况中，绝大多数为 “deletion” 型（如左图所示）的 SV，该类型的 SV 很大程度上会造成数据的缺失（如右图所示）：





K562	++	+-	-+	--	sum
TADs	0	6	0	0	6
10kb, reorganized TADs	2	12	7	1	22
25kb, reorganized TADs	2	12	7	2	23
DIPGXIII	++	+-	-+	--	sum
TADs	3	16	3	6	28
10kb, reorganized TADs	3	16	3	6	28
25kb, reorganized TADs	3	16	3	6	28
DIPG007	++	+-	-+	--	sum
TADs	6	16	10	7	39
10kb, reorganized TADs	6	16	10	7	39
25kb, reorganized TADs	6	16	10	7	39

左表展示的是不同细胞类型
和不同分辨率下，与
TADs/ 差异 TADs 无关的
SV 的个数，观察表格可以：

不同 celltype
下，“deletion” 类型的
SV 数量最多



结果总结与研究计划



结果总结

1. 基于大维随机矩阵理论下 DiffDomain 的方法检出率由 68.493% 提升至 **73.9437%** (已完成)
2. SVs 与 TADs 以及 差异 TADs 之间的位置关系统计 (overlap , breakpoints) 统计 (已完成)
3. SVs 与 差异 TADs 之间的相关性关系验证 (已完成)
4. DiffDomain 方法 识别 差异 TADs 的 R-package 开发 (已完成)
5. SVs 类型与差异 TADs 之间的关系 (部分完成)



研究计划安排

2023.06 SVs 类型 与差异 TADs 之间的关系探索

2023.07 对基于大维随机矩阵理论下改进后的 DiffDomain 完成 R-package 开发

2023.08 DiffDomain 方法在大维随机矩阵理论下的应用, 尝试提高检出率

2023.09 DiffDomain 方法对应的 classification (识别不同 类型 差异 TADs) 的 R-package 开发

2023.10 撰写论文



敬请批评指正

答辩人：张筱

指导老师：田德朝